

Estimativa da Condutividade Térmica e Capacidade Térmica Volumétrica via Problema Inverso com Diferenças Finitas e Algoritmo Genético

David Luiz Silva Rodrigues

29 de julho de 2026

1 Introdução

Problemas clássicos de engenharia, como a determinação de campos de temperatura e fluxos de calor, são tipicamente resolvidos por meio da abordagem direta, que utiliza equações governantes e propriedades conhecidas dos materiais, como a condutividade térmica (κ) e a capacidade térmica volumétrica (C). No entanto, a situação inversa também é de grande interesse prático: a partir de medições de temperatura em pontos específicos de um material, deseja-se estimar suas propriedades térmicas desconhecidas (κ e C). Essa formulação constitui um problema inverso, cuja resolução é tratada como um problema de otimização.

Nesse contexto, valores iniciais para κ e C são propostos e utilizados em uma simulação direta para o cálculo do campo de temperatura. Em seguida, os valores numéricos obtidos são comparados com as medições experimentais por meio de uma função objetivo. Esse processo iterativo se repete até que um critério de convergência seja satisfeito. A premissa fundamental do método inverso é que os parâmetros que minimizam a função objetivo representam a melhor estimativa para as propriedades reais do material. Vale ressaltar, contudo, que o sucesso dessa abordagem exige uma modelagem matemática rigorosa do problema físico, incorporando dimensões e condições de contorno adequadas.

Portanto, este trabalho tem como objetivo estimar a condutividade térmica e a capacidade térmica volumétrica de uma parede unidimensional a partir de medições de temperatura em uma das suas extremidades. Para o problema direto, empregou-se o método de diferenças finitas na discretização espacial com integrador temporal de Runge-Kutta de 4.^a ordem (RK4), devido à sua estabilidade numérica e simplicidade. O problema inverso é resolvido via algoritmo genético, cuja natureza metaheurística garante robustez e generalidade, dispensando o uso de derivadas ou cálculos analíticos complexos.

2 Fundamentação teórica

2.1 O problema direto

O problema de transferência de calor unidimensional em regime transiente, para um meio homogêneo e sem geração interna de calor, definido no domínio espacial $\Omega = (0, L)$ e no intervalo de tempo $I = (0, t_f]$, é descrito por:

$$\frac{\partial T}{\partial t} = \frac{\kappa}{C} \frac{\partial^2 T}{\partial x^2} \quad \text{em } \Omega \times I, \quad (1)$$

onde o sistema está sujeito à condição inicial $T(x, 0) = \bar{T}$ para $x \in \Omega$, e às seguintes condições de contorno para $t \in I$:

$$T(0, t) = \bar{T} \quad \text{e} \quad -\kappa \frac{\partial T}{\partial x}(L, t) = h(T(L, t) - T_\infty), \quad (2)$$

em que h é o coeficiente de transferência de calor por convecção e T_∞ é a temperatura do ambiente ao qual a fronteira $x = L$ está exposta. A Figura 1 exibe o domínio do problema e as condições de contorno.




Figura 1: Domínio e condições de contorno.

2.2 O problema inverso

Para a formulação do problema inverso, define-se primeiramente o vetor de parâmetros desconhecidos que se deseja estimar, composto pela condutividade térmica e pela capacidade térmica volumétrica:

$$\mathbf{X} = [\kappa, C]^T. \quad (3)$$

A resolução desse problema exige informações adicionais provenientes de medições experimentais. Assume-se que um sensor registra a temperatura de forma discreta ao longo do tempo na extremidade $x = L$. Seja T_i a temperatura medida no instante de tempo t_i , para $i = 1, 2, \dots, N_t$, onde N_t representa o número total de medições.

O problema inverso é, então, formulado como um problema de otimização de parâmetros. O objetivo é encontrar os valores de κ e C que minimizem a diferença entre os dados experimentais e a temperatura calculada pelo modelo direto. Utilizando soma do quadrado dos erros, a função objetivo é definida como:

$$S(\kappa, C) = \sum_{i=1}^{N_t} [T_i - T(L, t_i; \kappa, C)]^2, \quad (4)$$

em que $T(L, t_i; \kappa, C)$ representa a temperatura obtida pela solução numérica do problema direto na posição $x = L$ e no instante t_i , avaliada para os parâmetros κ e C propostos pelo algoritmo de otimização, enquanto T_i corresponde à temperatura dos dados pseudoexperimentais nessa mesma posição e instante.

Portanto, o problema inverso consiste em determinar o vetor de parâmetros ótimos $\mathbf{X}^*$ tal que:

$$\mathbf{X}^* = \arg \min_{\kappa, C} S(\kappa, C). \quad (5)$$

3 Métodos numéricos

O Método das Diferenças Finitas (MDF) foi empregado para a solução da Equação 1. O domínio espacial é discretizado por meio de uma malha uniforme com espaçamento definido por $\Delta x = \frac{L}{N+1}$, em que N é o número de nós internos. Por meio dessa abordagem, a discretização da derivada espacial transforma a equação diferencial parcial em um sistema de N equações diferenciais ordinárias (EDOs) em função do tempo, representadas por:

$$\frac{dT_i}{dt} = f_i(\mathbf{T}) = \frac{\kappa}{C} \left(\frac{T_{i+1} - 2T_i + T_{i-1}}{\Delta x^2} \right), \quad i = 1, 2, \dots, N. \quad (6)$$

Para a imposição das condições de contorno, criam-se nós fantasmas nas extremidades. Na fronteira $x = 0$, a temperatura prescrita $\bar{T}$ é imposta através do nó fantasma T_0 :

$$T_0 = 2\bar{T} - T_1. \quad (7)$$

Analogamente, a condição de contorno convectiva na fronteira $x = L$ (próxima ao nó N) é discretizada ao igualar o fluxo de condução e a convecção na interface, em que a temperatura superficial é estimada pela média dos nós T_N e T_{N+1} :

$$-\kappa \left(\frac{T_{N+1} - T_N}{\Delta x} \right) = h \left(\frac{T_{N+1} + T_N}{2} - T_\infty \right). \quad (8)$$

Isolando a temperatura do nó fantasma da extremidade, T_{N+1} , obtém-se a equação empregada na implementação numérica:

$$T_{N+1} = \frac{\left(\frac{\kappa}{\Delta x} - \frac{h}{2}\right) T_N + h T_\infty}{\frac{\kappa}{\Delta x} + \frac{h}{2}}. \quad (9)$$

A integração temporal do sistema de EDOs foi realizada pelo Método de Runge-Kutta de 4.^a Ordem (RK4). Para assegurar a estabilidade e a precisão da solução, o passo de tempo Δt foi determinado mantendo-se o número de Fourier fixo em $Fo = 0,5$, isto é, $\Delta t = \frac{0,5 \Delta x^2}{\kappa/C}$. A marcha no tempo entre os instantes t^n e t^{n+1} é dada pelo cálculo dos coeficientes intermediários para cada nó i :

$$k_{1,i} = f_i(\mathbf{T}^n), \quad (10)$$

$$k_{2,i} = f_i(\mathbf{T}^n + 0,5\Delta t \mathbf{k}_1), \quad (11)$$

$$k_{3,i} = f_i(\mathbf{T}^n + 0,5\Delta t \mathbf{k}_2), \quad (12)$$

$$k_{4,i} = f_i(\mathbf{T}^n + \Delta t \mathbf{k}_3), \quad (13)$$

com a atualização do vetor de temperatura dada por:

$$T_i^{n+1} = T_i^n + \frac{\Delta t}{6} (k_{1,i} + 2k_{2,i} + 2k_{3,i} + k_{4,i}). \quad (14)$$

A temperatura na extremidade $x = L$, a cada passo de tempo, foi obtida por meio da média aritmética entre os nós T_N e T_{N+1} . Com isso, foi possível construir o perfil temporal de temperaturas nessa extremidade para valores dados de κ e C , necessário para a minimização da função objetivo (Equação 4). O par (κ, C) representa um indivíduo da população no algoritmo genético binário do pacote BaumEvA 0.7.1¹. As etapas desse algoritmo são descritas a seguir:

1. **Inicialização:** Configuração dos parâmetros do algoritmo e geração da população inicial, na qual cada indivíduo representa o par (κ, C) .
2. **Avaliação da aptidão:** Solução do problema direto para obtenção das temperaturas em $x = L$ e cálculo da função objetivo (Equação 4) para cada indivíduo.
3. **Operadores genéticos:** A cada geração, aplicam-se seleção por torneio, cruzamento (*crossover*) e mutação para gerar uma nova população.
4. **Critério de parada:** O ciclo de evolução e reavaliação se repete até atingir o limite de gerações ou a estagnação da função objetivo.
5. **Obtenção do resultado:** Retorno do indivíduo com a menor função objetivo, fornecendo a estimativa final $\mathbf{X}^* = [\kappa^*, C^*]^T$.

4 Resultados

Os parâmetros adotados nas simulações foram: $L = 0,0254$ m, $t_f = 120$ s, $h = 10$ W/(m² · °C) e $\bar{T} = 100^\circ\text{C}$. O domínio numérico foi discretizado com 30 nós internos utilizando o Método das Diferenças Finitas (MDF). O passo de tempo foi estabelecido de modo a manter o número de Fourier fixo em $Fo = 0,5$, sendo ajustado dinamicamente para cada par de valores de κ e C . Os dados pseudoexperimentais foram gerados pelo próprio código numérico, assumindo-se o vetor de projeto $\mathbf{X} = [45 \quad 3600000]^T$. Para reproduzir as incertezas de medição inerentes a um aparato físico, adicionou-se um ruído gaussiano (com média nula e desvio padrão de $0,5^\circ\text{C}$) às temperaturas calculadas na fronteira $x = L$ dos dados pseudoexperimentais. Por fim, o algoritmo genético foi executado em três rodadas, cada uma configurada com uma população de 20 indivíduos, 100 iterações e taxa de mutação de 35%. Além disso, os intervalos de busca foram definidos como $1 < \kappa < 100$ e $1 \cdot 10^6 < C < 5 \cdot 10^6$.

A Tabela 1 apresenta a estimativa dos parâmetros κ e C obtida em cada rodada do algoritmo genético, bem como os respectivos valores da função objetivo e o custo computacional. Os resultados

¹Criado por Aleksei Kudryavtsev e disponível em <https://pypi.org/project/baumeva/>

evidenciam o caráter randômico inerente à metodologia: por se tratar de uma metaheurística, cada execução gera uma solução distinta. A melhor resposta foi obtida na Rodada 2, com um erro relativo inferior a 10% (para cada variável) em relação aos parâmetros reais, um desempenho bastante satisfatório considerando a presença de ruído nos dados.

Rodada	$\mathbf{X}^*$	$S(\kappa, C)$	Tempo [s]
1	$[53,3 \ 4\ 273\ 661,6]^T$	756,6	605
2	$[41,0 \ 3\ 278\ 288,3]^T$	747,0	578
3	$[49,5 \ 3\ 975\ 656,7]^T$	757,5	590

Tabela 1: Solução ótima de cada rodada e estatísticas.

A Figura 2 exibe a comparação entre os dados pseudoexperimentais e a solução numérica fornecida pelo vetor de projeto dessa rodada, em que $\mathbf{X}^* = [41,0 \ 3\ 278\ 288,3]^T$. Cabe ressaltar que um resultado tão preciso poderia não ter sido alcançado em apenas três rodadas, o que reforça a importância do uso de réplicas em otimizações com metaheurística. Além disso, como cada execução demandou aproximadamente 10 minutos, estratégias de paralelização e otimização do código revelam-se úteis para a aplicação do método em problemas de maior dimensão.




Figura 2: Dados pseudoexperimentais e da solução ótima na posição $x = L$.

5 Conclusão

Neste estudo, resolveu-se um problema inverso unidimensional de transferência de calor para a estimativa simultânea da condutividade térmica (κ) e da capacidade térmica volumétrica (C). A metodologia mostrou-se robusta e precisa, obtendo parâmetros com erro inferior a 10%, mesmo com a adição de ruído aos dados pseudoexperimentais. Como trabalhos futuros, recomenda-se a otimização do código e a implementação de paralelização (como *OpenMP* ou *CUDA*). Essas melhorias permitirão aumentar o tamanho da população, o número de iterações e a quantidade de rodadas.